

RAPPORT DE PROJET

Analyse de Survie Application au Cancer du Sein

Projet réalisé dans le cadre de la formation

Licence en Mathématiques - Parcours Statistiques et Applications

Module : Analyse de Données et Modèles Statistiques

Travail réalisé par :

- Katr Nada MAATALLAH
- Cherifa AMIR

Enseignant : Yousri SLAOUI

Année universitaire 2025/2026

Table des matières

Introduction générale	1
Chapitre I : État de l’art	3
Introduction	4
1 Concepts fondamentaux de l’analyse de survie	4
1.1 Temps de survie et événement	4
1.2 Types de censure	5
1.3 Fonction de survie	5
1.4 Fonction de risque	5
2 Méthodes statistiques en analyse de survie	6
2.1 Estimateur de Kaplan–Meier	6
2.2 Comparaison des courbes : test du log-rank	7
2.3 Modèle de Cox	7
2.4 Modèles paramétriques : AFT	7
2.5 Risque cumulatif et courbes ajustées	8
3 Visualisation : apport de ggplot2	8
4 Applications dans le cancer du sein	8
Conclusion	9
Chapitre II : Présentation du jeu de données	10
Introduction	11
1 Description des variables	11
2 Préparation et nettoyage	12
3 Construction des variables de survie	14
4 Analyse descriptive	14
Conclusion	18
Chapitre III : Analyse statistique	19
Introduction	20
1 Kaplan–Meier global	20
2 Kaplan–Meier par groupes	21

3	Comparaison par test du log-rank	22
4	Modèle de Cox	23
5	Vérification des hypothèses	24
6	Visualisations avancées : courbes ajustées	25
	Conclusion	26
Chapitre IV : Application interactive		27
	Introduction	28
1	Objectifs de l'application	28
2	Description du tableau de bord	28
3	Analyse descriptive interactive	29
4	Analyse de survie interactive	30
	Conclusion	31
Conclusion générale		32
Bibliographie		33

Table des figures

1	Logo du langage R	4
2	Library Survex	6
3	Library ggplot2	8
4	Chargement du jeu de données GBSG2	12
5	Vérification des valeurs manquantes sous R	12
6	Pourcentage de valeurs manquantes par variable	13
7	Recodage des variables qualitatives sous R.	13
8	Création de l'objet de survie Surv.	14
9	Distribution de l'âge des patientes (age).	15
10	Distribution de la taille tumorale (tsize).	15
11	Matrice de corrélations entre les variables quantitatives principales.	16
12	Répartition des patientes selon l'administration d'une hormonothérapie (horTh).	17
13	Répartition des patientes selon le grade tumoral (tgrade).	17
14	Estimation de la courbe de Kaplan–Meier globale.	20
15	Courbe de Kaplan–Meier globale avec intervalle de confiance.	20
16	Table des patientes à risque au cours du temps.	21
17	Estimation des courbes de Kaplan–Meier par groupes.	21
18	Courbes de Kaplan–Meier selon le traitement hormonal.	21
19	Table des patientes à risque selon le traitement hormonal.	22
20	Test du log-rank sous R.	22
21	Ajustement des modèles de Cox.	23
22	Forest plot du modèle de Cox multivarié.	24
23	Test des risques proportionnels.	24
24	Diagnostics graphiques des résidus de Schoenfeld.	25
25	Génération des courbes de survie ajustées.	25
26	Courbes ajustées issues du modèle de Cox multivarié.	25
27	Logo Shiny	28
28	Tableau de bord de l'application R Shiny	29
29	Analyse descriptive interactive des variables cliniques dans l'application R Shiny.	30

30	Courbes de Kaplan–Meier interactives générées par l’application R Shiny.	31
----	--	----

Introduction générale

Le cancer du sein représente aujourd’hui l’un des principaux enjeux de santé publique à l’échelle mondiale. Il s’agit du cancer le plus fréquemment diagnostiqué chez la femme et l’un des plus étudiés en épidémiologie, en biostatistique et en recherche clinique. Les progrès réalisés en matière de dépistage, d’imagerie, de thérapies ciblées et de stratégies de suivi ont contribué à améliorer considérablement le pronostic des patientes. Toutefois, la compréhension des facteurs influençant la survie ou la récurrence demeure essentielle pour adapter et optimiser les protocoles de traitement.

L’analyse de survie s’impose comme un outil statistique particulièrement adapté pour étudier un temps avant événement tout en intégrant la présence de données censurées. Contrairement aux approches classiques, elle permet de tenir compte du fait que certaines patientes ne présentent pas l’événement d’intérêt au cours du suivi (fin d’étude, perte de vue, absence de récurrence, etc.). Les méthodes développées dans ce domaine, telles que les courbes de Kaplan–Meier ou les modèles de Cox, permettent d’estimer la survie, de comparer des groupes et d’évaluer l’impact de facteurs cliniques sur le risque d’événement.

Les analyses réalisées dans ce projet s’appuient sur le langage **R** et plusieurs bibliothèques spécialisées, dont `survival`, `survminer`, `ggplot2` et `dplyr`. Ces outils permettent de manipuler les données, d’estimer et de visualiser les courbes de survie, d’ajuster des modèles semi-paramétriques, et de produire des graphiques clairs et reproductibles.

L’objectif de ce travail est d’étudier les données cliniques issues de la base GBSG2, provenant d’un essai clinique portant sur des patientes atteintes d’un cancer du sein opérable. À travers ce jeu de données, nous cherchons à :

- présenter et expliquer les notions théoriques utilisées en analyse de survie ;

- décrire le jeu de données et les variables étudiées ;
- effectuer une exploration descriptive des patientes ;
- appliquer différentes méthodes statistiques : Kaplan–Meier, test du log-rank, modèles de Cox univariés et multivariés, diagnostics de l’hypothèse de risques proportionnels, risques cumulatifs et courbes ajustées ;
- interpréter les résultats dans un contexte biomédical.

Toutes les analyses et figures sont générées de manière reproductible avec R.

Le rapport est organisé en quatre chapitres : un état de l’art présentant les fondements de l’analyse de survie, une description du jeu de données utilisé, une analyse statistique détaillée, puis une discussion suivie d’une conclusion générale.

Ce travail illustre comment les méthodes de survie permettent de mieux comprendre l’évolution clinique des patientes, d’évaluer l’influence de différents facteurs et de contribuer à l’aide à la décision dans un contexte médical réel.

Chapitre I

État de l'art

Introduction

L'analyse de survie regroupe l'ensemble des méthodes statistiques permettant d'étudier un temps avant événement : décès, récurrence, progression, arrêt d'un traitement ou tout autre événement d'intérêt. La particularité de ces données est qu'elles peuvent être incomplètes : il est fréquent que certaines patientes ne présentent pas l'événement au cours du suivi. Elles sont alors dites censurées. Comme l'explique le support pédagogique « Analyse de survie avec R », un modèle statistique classique est généralement inadapté à ce type de données en raison du manque de normalité, de l'hétérogénéité des durées et de la censure.



FIGURE 1 – Logo du langage R

La censure n'indique pas une absence d'information ; elle signale seulement que l'événement n'a pas été observé au cours de la période d'étude. Cette spécificité exige des méthodes dédiées, capables de produire des estimations non biaisées malgré la présence de données incomplètes. L'analyse de survie est donc devenue un pilier essentiel en épidémiologie et en oncologie, notamment pour évaluer des traitements, suivre des cohortes de patientes ou estimer des indicateurs pronostiques.

1 Concepts fondamentaux de l'analyse de survie

1.1 Temps de survie et événement

Pour chaque patiente, on observe un couple (t_i, δ_i) où :

$$\delta_i = \begin{cases} 1 & \text{si l'événement est observé} \\ 0 & \text{si l'observation est censurée} \end{cases}$$

Le temps t_i peut correspondre à :

- la durée avant récurrence ;

- la durée avant décès ;
- la durée avant progression tumorale ;
- ou toute autre durée d'intérêt clinique.

1.2 Types de censure

Les données peuvent présenter plusieurs types de censure :

- Censure à droite : l'événement n'est pas survenu pendant le suivi (le cas le plus courant).
- Censure à gauche : la date exacte de début n'est pas connue.
- Censure par intervalle : l'événement est connu comme ayant eu lieu dans un intervalle donné.

La plupart des méthodes utilisées dans ce projet supposent une censure non informative : le fait d'être censuré ne doit pas dépendre du risque réel de l'événement.

1.3 Fonction de survie

La fonction de survie est définie par :

$$S(t) = \Pr(T > t) \quad (1)$$

Elle mesure la probabilité qu'une patiente survive au-delà du temps t .

Propriétés importantes :

- $S(0) = 1$;
- $S(t)$ est décroissante ;
- la médiane de survie correspond à l'instant où $S(t) = 0,5$.

1.4 Fonction de risque

La fonction de risque instantané (hazard) est définie par :

$$h(t) = \lim_{\Delta t \rightarrow 0} \frac{\Pr(t \leq T < t + \Delta t \mid T \geq t)}{\Delta t} \quad (2)$$

Elle représente la vitesse instantanée de survenue de l'événement, à un temps donné, parmi les patientes encore en vie à cet instant.

2 Méthodes statistiques en analyse de survie



FIGURE 2 – Library Survex

2.1 Estimateur de Kaplan–Meier

La méthode de Kaplan–Meier est non paramétrique. Elle estime la fonction de survie comme un produit de probabilités conditionnelles :

$$S(t_i) = S(t_{i-1}) \left(1 - \frac{d_i}{n_i} \right) \quad (3)$$

où :

- n_i : nombre de patientes encore à risque juste avant t_i ;
- d_i : nombre d'événements observés à t_i .

Hypothèses classiques du KM (résumées du PDF) :

- événement binaire (vivante / décédée) ;
- temps connus précisément (non en intervalle) ;
- censure non informative ;
- absence de changements structurels majeurs au cours du suivi (pas d'effets cohorte) ;
- modèles de censure similaires entre groupes.

2.2 Comparaison des courbes : test du log-rank

Le test du log-rank permet de comparer deux ou plusieurs courbes de survie :

$$H_0 : S_1(t) = S_2(t) \quad (4)$$

Il s'agit de l'outil standard pour évaluer l'effet d'un traitement dans les études cliniques.

2.3 Modèle de Cox

Le modèle de Cox généralise les méthodes de survie pour tenir compte de plusieurs covariables simultanément :

$$h(t \mid X) = h_0(t) \exp(\beta_1 X_1 + \cdots + \beta_p X_p) \quad (5)$$

Interprétation :

- $\exp(\beta)$ est le hazard ratio (HR) ;
- $\text{HR} > 1$: augmentation du risque ;
- $\text{HR} < 1$: effet protecteur ;
- $\text{HR} = 1$: absence d'effet.

Le modèle repose sur l'hypothèse des risques proportionnels : les risques relatifs doivent rester constants au cours du temps.

2.4 Modèles paramétriques : AFT

Le modèle AFT (Accelerated Failure Time) propose une alternative paramétrique :

$$S(t \mid Z) = S_0(t \cdot e^{\beta Z}) \quad (6)$$

Il modélise directement l'effet des covariables sur le temps de survie (accélération ou ralentissement du temps) et non sur le risque instantané.

2.5 Risque cumulatif et courbes ajustées

Les méthodes modernes permettent également de calculer :

- le risque cumulatif (ou cumulative hazard) ;
- les courbes ajustées issues d'un modèle de Cox ;
- les forest plots des HR.

3 Visualisation : apport de ggplot2




FIGURE 3 – Library ggplot2

Les outils `ggplot2` et `survminer` facilitent la création de :

- courbes Kaplan–Meier personnalisées ;
- tables de risque ;
- forest plots de Cox ;
- courbes ajustées ;
- graphiques du risque cumulatif.

Ces visualisations permettent une interprétation claire et reproductible, ce qui est essentiel dans les études cliniques.

4 Applications dans le cancer du sein

Le cancer du sein constitue un domaine majeur d'application de l'analyse de survie. Les méthodes présentées permettent d'évaluer :

- l'efficacité des traitements (ex. hormonothérapie) ;

- l’impact de facteurs biologiques ou cliniques ;
- la survie médiane et les taux de survie ;
- les effets combinés de plusieurs variables.

Le dataset GBSG2 utilisé dans ce projet illustre parfaitement ces problématiques et permet d’appliquer l’ensemble des méthodes présentées dans ce chapitre.

Conclusion

Cet état de l’art a présenté les notions fondamentales de l’analyse de survie, les principales méthodes statistiques, ainsi que les outils modernes d’estimation et de visualisation. Ces éléments constituent la base méthodologique pour les analyses réalisées dans les chapitres suivants.

Chapitre II

Présentation du jeu de données

Introduction

Ce chapitre est consacré à la présentation du jeu de données utilisé dans ce projet, issu de l'étude GBSG2 disponible dans le package `TH.data` de R. Il s'agit d'un ensemble de données cliniques portant sur 686 patientes traitées pour un cancer du sein opérable. Les informations recueillies concernent notamment l'âge, la taille tumorale, le nombre de ganglions positifs, les récepteurs hormonaux, le statut hormonal, le traitement reçu et la durée de suivi.

1 Description des variables

Le jeu de données GBSG2 contient les variables suivantes :

Variables qualitatives

- `horTh` : traitement hormonal (valeurs possibles : "no", "yes"), indiquant si une hormonothérapie adjuvante a été administrée.
- `menostat` : statut ménopausique au moment du diagnostic ("Pre" pour pré-ménopausée, "Post" pour postménopausée).
- `tgrade` : grade tumoral histologique ("I", "II", "III"), reflétant le degré de différenciation de la tumeur.
- `cens` : indicateur d'événement (0 pour observation censurée, 1 pour événement observé).

Variables quantitatives

- `age` : âge de la patiente (en années) au moment du diagnostic.
- `tsize` : taille tumorale (en millimètres).
- `pnodes` : nombre de ganglions lymphatiques positifs.
- `progrec` : taux de récepteurs à la progestérone.
- `estrec` : taux de récepteurs aux œstrogènes.
- `time` : durée de suivi (en jours) jusqu'à l'événement ou la censure.

Un aperçu des dix premières lignes du tableau de données est présenté à la Tableau 1.

TABLE 1 – Aperçu des premières lignes du jeu de données GBSG2.

horTh	age	menostat	tsize	tgrade	pnodes	progrec	estrec	time	cens
no	70	Post	21	II	3	48	66	1814	1
yes	56	Post	12	II	7	61	77	2018	1
yes	58	Post	35	II	9	52	271	712	1
yes	59	Post	17	II	4	60	29	1807	1
no	73	Post	35	II	1	26	65	772	1

2 Préparation et nettoyage

Les données ont été chargées depuis le package `TH.data` à l'aide de la commande `data("GBSG2")`. Une première étape a consisté à examiner la structure générale du jeu de données, les types de variables et la cohérence des formats, à l'aide des fonctions `str()` et `summary()` du langage R.

```
library(TH.data)
data("GBSG2")
df <- GBSG2
str(df)
summary(df)
```

FIGURE 4 – Chargement du jeu de données GBSG2

Une vérification systématique de la présence de valeurs manquantes a ensuite été réalisée à l'aide de la fonction `gg_miss_var()` du package `naniar`.

```
library(naniar)
gg_miss_var(df)
```

FIGURE 5 – Vérification des valeurs manquantes sous R

Cette absence de valeurs manquantes constitue un avantage important pour l'analyse : les méthodes de survie peuvent être appliquées directement sans recourir à des

procédures d'imputation, ce qui garantit la simplicité et la fiabilité des estimations réalisées par la suite.




FIGURE 6 – Pourcentage de valeurs manquantes par variable

Les variables qualitatives ont été vérifiées puis, lorsque nécessaire, recodées sous forme de facteurs afin de refléter correctement leur nature catégorielle. Cette étape concerne notamment les variables `horTh`, `menostat` et `tgrade`, comme illustré par le script présenté à la Figure 7. Les variables quantitatives ont été conservées sous forme numérique.

```
df <- df %>%
  mutate(
    horTh = factor(horTh, levels=c("no", "yes")),
    menostat = factor(menostat, levels=c("Pre", "Post")),
    tgrade = factor(tgrade, ordered = TRUE)
  )
```

FIGURE 7 – Recodage des variables qualitatives sous R.

Cette étape de préparation garantit une base cohérente et adaptée pour la construction des objets de survie et l'application des méthodes statistiques présentées dans le chapitre suivant.

3 Construction des variables de survie

Dans le cadre de l'analyse de survie, deux éléments sont indispensables :

- une variable de temps, ici `time`, représentant la durée de suivi en jours ;
- un indicateur d'événement, ici `cens`, égal à 1 en cas d'événement observé et à 0 en cas de censure.

Ces deux composantes ont été combinées afin de construire un objet de type `Surv` du package `survival`, comme illustré à la Figure 8. Cet objet formalise l'information de survie contenue dans les données et constitue l'entrée principale pour l'estimation des courbes de Kaplan–Meier et l'ajustement des modèles de Cox.

```
surv_object <- Surv(time = df$time, event = df$cens)
head(surv_object)
```

FIGURE 8 – Création de l'objet de survie `Surv`.

4 Analyse descriptive

Une analyse descriptive a été réalisée afin de mieux comprendre la structure du jeu de données et les caractéristiques cliniques des patientes incluses dans l'étude.

Variables quantitatives :

L'âge des patientes s'étend d'environ 20 à 80 ans. L'histogramme de la Figure 9 montre une distribution unimodale, légèrement asymétrique, avec une concentration majoritaire entre 45 et 65 ans.

Ce profil correspond à la tranche d'âge typiquement observée dans les études sur le cancer du sein.




FIGURE 9 – Distribution de l'âge des patientes (`age`).

La taille tumorale (`tsize`) présente une distribution beaucoup plus asymétrique (Figure 10). La majorité des patientes ont une tumeur comprise entre 10 et 40 mm, mais quelques observations extrêmes dépassent 80 à 100 mm, ce qui reflète la présence de tumeurs localement avancées.




FIGURE 10 – Distribution de la taille tumorale (`tsize`).

Une matrice de corrélation a été établie pour les variables quantitatives (Figure 11). On observe notamment :

- une corrélation positive notable entre les récepteurs aux œstrogènes (**estrec**) et les récepteurs à la progestérone (**progrec**), reflet attendu de la biologie tumorale hormonodépendante ;
- une corrélation négative modérée entre le nombre de ganglions positifs (**pnodes**) et la durée de survie (**time**) : les patientes présentant davantage de ganglions atteints ont en moyenne une survie plus courte ;
- une faible corrélation entre l'âge et la durée de survie.



FIGURE 11 – Matrice de corrélations entre les variables quantitatives principales.

Variables qualitatives :

La variable **horTh**, représentant l'administration ou non d'une hormonothérapie adjuvante, présente une répartition asymétrique (Figure 12). Environ 440 patientes n'ont pas reçu de traitement hormonal, contre environ 240 qui en ont bénéficié. Cette différence de fréquence pourrait influencer les résultats des modèles de survie et justifie une comparaison ultérieure entre groupes.




FIGURE 12 – Répartition des patientes selon l’administration d’une hormonothérapie (horTh).

Le grade tumoral (**tgrade**) présente également une répartition non uniforme (Figure 13). Le grade II est largement majoritaire, suivi du grade III et enfin du grade I, ce qui correspond à une répartition clinique typique. La prédominance des grades élevés reflète la sévérité globale des cas inclus dans l’étude et pourrait jouer un rôle dans la survie.




FIGURE 13 – Répartition des patientes selon le grade tumoral (**tgrade**).

Enfin, l’indicateur **cens** révèle une proportion importante d’observations censurées,

ce qui rend nécessaire l'utilisation de méthodes adaptées pour l'analyse de survie. Une analyse descriptive par groupe (selon `horTh`) montre que les patientes ayant reçu une hormonothérapie présentent en moyenne un âge légèrement plus élevé et des valeurs biologiques différentes, justifiant les modèles ajustés développés au chapitre suivant.

Conclusion

Ce chapitre a décrit le jeu de données GBSG2, ses principales variables et leurs caractéristiques, ainsi que les étapes de préparation et de nettoyage réalisées avant l'analyse. L'absence de valeurs manquantes et la structure bien définie des variables constituent un cadre favorable pour l'application des méthodes d'analyse de survie. L'analyse descriptive a permis de mettre en évidence la diversité des profils cliniques et biologiques des patientes, ainsi que la présence de censure, qui sera prise en compte dans les modèles présentés au chapitre suivant.

Chapitre III

Analyse statistique

Introduction

Ce chapitre présente les méthodes d'analyse de survie appliquées au jeu de données GBSG2. Après l'estimation de la fonction de survie globale par la méthode de Kaplan–Meier, une comparaison entre groupes est réalisée à l'aide du test du log-rank. Des modèles de Cox univarié et multivarié sont ensuite ajustés afin d'évaluer l'effet de plusieurs facteurs cliniques sur le risque de survenue de l'événement. Enfin, l'hypothèse de risques proportionnels est vérifiée et des courbes de survie ajustées sont présentées.

1 Kaplan–Meier global

La fonction de survie globale a été estimée à l'aide de la méthode de Kaplan–Meier, comme illustré par le script présenté à la Figure 14.

```
km_global <- survfit(surv_object ~ 1, data = df)
```

FIGURE 14 – Estimation de la courbe de Kaplan–Meier globale.

La Figure 15 présente la courbe de survie obtenue pour l'ensemble des patientes.




FIGURE 15 – Courbe de Kaplan–Meier globale avec intervalle de confiance.

La survie décroît progressivement au cours du temps, avec une médiane située autour de 1800 jours.

Le tableau des patientes à risque est présenté à la Figure 16.




FIGURE 16 – Table des patientes à risque au cours du temps.

2 Kaplan–Meier par groupes

Afin d’étudier l’effet du traitement hormonal (`horTh`), des courbes de Kaplan–Meier ont été estimées séparément pour chaque groupe.

```
km_group <- survfit(Surv(time, cens) ~ horTh, data = df)
```

FIGURE 17 – Estimation des courbes de Kaplan–Meier par groupes.




FIGURE 18 – Courbes de Kaplan–Meier selon le traitement hormonal.

La Figure 18 montre que les courbes de survie divergent progressivement, suggérant un effet potentiel du traitement hormonal. Le tableau des patientes à risque associé est présenté à la Figure 19.




FIGURE 19 – Table des patientes à risque selon le traitement hormonal.

3 Comparaison par test du log-rank

La comparaison des courbes de survie a été réalisée à l'aide du test du log-rank, dont l'implémentation est illustrée à la Figure 20.

```
> logrank <- survdiff(Surv(time, cens) ~ horTh, data=df)
> logrank
Call:
survdiff(formula = Surv(time, cens) ~ horTh, data = df)

      N Observed Expected (O-E)^2/E (O-E)^2/V
horTh=no 440      205      180      3.37      8.56
horTh=yes 246       94      119      5.12      8.56

Chisq= 8.6 on 1 degrees of freedom, p= 0.003
```

FIGURE 20 – Test du log-rank sous R.

La statistique du test est donnée par :

$$\chi^2 = 8.56, \quad df = 1, \quad p = 0.003.$$

La p-valeur ($p < 0,01$) indique une différence significative entre les groupes : les patientes recevant une hormonothérapie présentent une survie significativement plus élevée.

4 Modèle de Cox

Des modèles de Cox ont été ajustés afin d'évaluer l'effet des variables cliniques sur le risque de survenue de l'événement. Le script correspondant est présenté à la Figure 21.

```
cox_uni   <- coxph(surv(time, cens) ~ horTh, data = df)
cox_multi <- coxph(surv(time, cens) ~ age + horTh + tgrade + menostat,
                  data = df)
```

FIGURE 21 – Ajustement des modèles de Cox.

Modèle univarié

Le modèle univarié évaluant l'effet du traitement hormonal donne :

$$HR = 0.69, \quad IC_{95\%} = [0.54, 0.89], \quad p = 0.0036.$$

L'hormonothérapie est associée à une réduction du risque de décès d'environ 31%.

Modèle multivarié

Le modèle multivarié inclut l'âge, le traitement hormonal, le grade tumoral et le statut ménopausique. Les principaux résultats sont résumés ci-dessous :

- **Hormonothérapie** : $HR = 0.70$, $p = 0.005$;
- **Grade tumoral** : augmentation significative du risque avec le grade ;
- **Statut ménopausique** : effet non significatif ;
- **Âge** : aucun effet significatif.

Le forest plot correspondant est présenté à la Figure 22.




FIGURE 22 – Forest plot du modèle de Cox multivarié.

5 Vérification des hypothèses

L'hypothèse de risques proportionnels a été testée à l'aide des résidus de Schoenfeld, comme illustré à la Figure 23.

```
> cox_zph_test <- cox.zph(cox_multi)
> cox_zph_test
```

	chisq	df	p
age	7.609	1	0.0058
horTh	0.209	1	0.6478
tgrade	12.937	2	0.0016
menostat	5.158	1	0.0231
GLOBAL	19.988	5	0.0013

FIGURE 23 – Test des risques proportionnels.

Le test global est significatif ($p_{\text{global}} = 0.0013$), indiquant des violations pour certaines covariables. Les diagnostics graphiques sont présentés à la Figure 24.




FIGURE 24 – Diagnostics graphiques des résidus de Schoenfeld.

6 Visualisations avancées : courbes ajustées

Des courbes de survie ajustées ont été générées à partir du modèle de Cox multivarié, comme indiqué par le script de la Figure 25.

```
ggadjustedcurves(cox_multi, data = df, variable = "horTh")
```

FIGURE 25 – Génération des courbes de survie ajustées.




FIGURE 26 – Courbes ajustées issues du modèle de Cox multivarié.

La Figure 26 montre que, même après ajustement pour l'âge, le grade tumoral et le statut ménopausique, l'hormonothérapie reste associée à une meilleure survie.

Conclusion

Ce chapitre a mis en évidence le rôle pronostique majeur de l'hormonothérapie dans l'étude GBSG2. Les modèles de Cox confirment l'importance du grade tumoral, tandis que certaines violations de l'hypothèse de risques proportionnels reflètent la complexité des données cliniques réelles sans remettre en cause la cohérence globale des résultats.

Chapitre IV

Application interactive

Introduction

Dans le prolongement des analyses statistiques réalisées aux chapitres précédents, une application interactive a été développée à l'aide du framework **R Shiny**. L'objectif de cette application est de proposer une interface graphique permettant d'explorer dynamiquement les données GBSG2 et les résultats de l'analyse de survie, sans nécessiter de connaissances approfondies en programmation R.



FIGURE 27 – Logo Shiny

1 Objectifs de l'application

L'application développée poursuit plusieurs objectifs complémentaires :

- faciliter l'exploration descriptive des données cliniques du jeu GBSG2 ;
- permettre une visualisation interactive des distributions des variables quantitatives et qualitatives ;
- offrir une représentation dynamique des courbes de Kaplan–Meier ;
- comparer la survie entre différents groupes de patientes (notamment selon le traitement hormonal) ;
- illustrer concrètement les concepts théoriques présentés dans le rapport.

L'application ne vise pas à remplacer l'analyse statistique formelle, mais à en proposer une lecture complémentaire, plus intuitive et accessible.

2 Description du tableau de bord

L'interface de l'application repose sur une structure classique de type `sidebarLayout`, comprenant :

- une barre latérale dédiée aux paramètres de sélection ;
- une zone principale d’affichage des graphiques et tableaux interactifs.

La barre latérale permet à l’utilisateur de sélectionner les variables d’intérêt, de filtrer les patientes selon certaines caractéristiques cliniques (traitement hormonal, statut ménopausique, etc.) et de choisir le type d’analyse à afficher.




FIGURE 28 – Tableau de bord de l’application R Shiny

La zone principale affiche les résultats sous forme de graphiques interactifs (histogrammes, courbes de survie) ainsi que, le cas échéant, de tableaux récapitulatifs mis à jour dynamiquement.

3 Analyse descriptive interactive

Une première partie de l’application est consacrée à l’analyse descriptive interactive des données. Elle permet d’explorer les principales variables quantitatives et qualitatives du jeu de données GBSG2.

Pour les variables quantitatives (âge, taille tumorale, nombre de ganglions positifs, récepteurs hormonaux), l’application propose des histogrammes interactifs ainsi que des statistiques descriptives .

Pour les variables qualitatives (traitement hormonal, grade tumoral, statut méno-

pausique), des graphiques en barres permettent de visualiser la répartition des patientes et d'observer l'évolution de la population selon les critères choisis.




FIGURE 29 – Analyse descriptive interactive des variables cliniques dans l'application R Shiny.

Cette interactivité facilite l'identification de tendances, de déséquilibres entre groupes et de caractéristiques spécifiques à certaines sous-populations.

4 Analyse de survie interactive

La seconde partie de l'application est dédiée à l'analyse de survie. Elle repose sur la construction dynamique d'objets de type `Surv` et l'estimation de courbes de Kaplan–Meier.

L'utilisateur peut :

- afficher la courbe de survie globale ;
- comparer les courbes de survie selon un facteur choisi (par exemple le traitement hormonal) ;
- visualiser les intervalles de confiance associés ;
- observer la table des patientes à risque en fonction du temps.




FIGURE 30 – Courbes de Kaplan-Meier interactives générées par l’application R Shiny.

Les graphiques sont automatiquement mis à jour en fonction des filtres appliqués dans l’interface. Cette approche permet de comprendre de manière intuitive l’effet des variables cliniques sur la survie, ainsi que l’influence de la censure.

Bien que l’application ne réalise pas d’inférence statistique avancée (tests formels ou modèles multivariés complexes), elle constitue un support pertinent pour illustrer les résultats obtenus dans le chapitre d’analyse statistique.

Conclusion

Ce chapitre a présenté une application interactive développée avec R Shiny pour l’exploration des données GBSG2 et l’illustration des méthodes d’analyse de survie. Cette application complète les analyses présentées précédemment en proposant une approche visuelle et dynamique, particulièrement adaptée à un contexte pédagogique. Elle met en évidence l’intérêt des outils interactifs pour la compréhension et la communication des résultats statistiques, tout en soulignant la nécessité de les associer à des analyses formelles rigoureuses.

Conclusion générale

L'analyse de survie constitue un cadre statistique essentiel pour l'étude de phénomènes cliniques caractérisés par un temps avant événement et la présence de données censurées. Dans ce travail, ces méthodes ont été appliquées au jeu de données GBSG2, issu d'un essai clinique portant sur des patientes atteintes d'un cancer du sein opérable, afin d'analyser la survie et d'identifier des facteurs pronostiques pertinents.

L'analyse descriptive a permis de caractériser la population étudiée et de mettre en évidence l'hétérogénéité des profils cliniques et biologiques. Les courbes de Kaplan-Meier ont fourni une estimation non paramétrique de la survie globale et par groupes, révélant des différences notables selon l'exposition à l'hormonothérapie, confirmées par le test du log-rank.

Les modèles de régression de Cox, ajustés de manière univariée puis multivariée, ont permis de quantifier l'impact des principaux facteurs cliniques sur le risque de décès. L'hormonothérapie apparaît comme un facteur protecteur indépendant, tandis que le grade tumoral s'impose comme un déterminant majeur du pronostic. Bien que certaines violations de l'hypothèse des risques proportionnels aient été observées, elles reflètent la complexité des données cliniques réelles sans remettre en cause la cohérence globale des résultats.

Enfin, une application interactive développée à l'aide de R Shiny a permis de valoriser les analyses réalisées en facilitant l'exploration des données et la compréhension des résultats. Ce projet met ainsi en évidence la complémentarité des méthodes statistiques et des outils de visualisation pour l'étude des trajectoires cliniques dans le cadre du cancer du sein.

Bibliographie

- [1] R CORE TEAM. *R Project — Logos*. 2025. URL : <https://www.r-project.org/logo/> (visité le 16/12/2025).
- [2] Terry THERNEAU. *CRAN : survival — Survival Analysis*. 2025. URL : <https://cran.r-project.org/package=survival> (visité le 16/12/2025).
- [3] Alboukadel KASSAMBARA. *CRAN : survminer — Drawing Survival Curves using ggplot2*. 2025. URL : <https://cran.r-project.org/package=survminer> (visité le 16/12/2025).
- [4] Hadley WICKHAM, Winston CHANG et al. *CRAN : ggplot2 — Create Elegant Data Visualisations Using the Grammar of Graphics*. 2025. URL : <https://cran.r-project.org/package=ggplot2> (visité le 16/12/2025).
- [5] POSIT SOFTWARE, PBC. *Shiny for R*. 2025. URL : <https://shiny.posit.co/r/> (visité le 16/12/2025).
- [6] Torsten HOTHORN, Brian EVERITT et al. *CRAN : TH.data — TH's Data Archive*. 2025. URL : <https://cran.r-project.org/package=TH.data> (visité le 16/12/2025).